金融大数据处理技术实验二(任务三: 用户活跃度分析)

221275010 屈航

1、设计思路

1.1、 Mapper的设计思路

Mapper 重构了一个 map 函数。

map 函数主要实现了对 user_balance_table.csv 表中的每一个用户的活跃天数进行统计,有直接购买(direct_purchase_amt 字段大于 0)或赎回行为(total_redeem_amt 字段大于 0)时,则该用户当天活跃。实现的过程就是对满足条件 directPurchaseAmt.compareTo(BigInteger.ZERO) > 0 ll totalRedeemAmt.compareTo(BigInteger.ZERO) > 0 的条目进行键值对的写入 context.write(userId, one)表示找到该用户有一天活跃;否则就写入 context.write(userId, new LongWritable(0))表示该用户在这一天不活跃。

因为考虑到求和得到的数据量可能很大,导致会超出 int 类型的表示范围,故实现的过程中的资金流入流出量的数据类型都是 BigInteger。

因为要传输两个值,即每日的 total_purchase_amt 资金流入与 [total_redeem_amt 资金流出,故可以把这两个数据作为一个 BalanceWritable 类来作为 value 进行键值对的传输。

以下是BalanceWritable 类的部分构造语句:

```
public static class BalanceWritable implements Writable {
       private BigInteger inflow;
       private BigInteger outflow;
       public BalanceWritable() {
            this.inflow = BigInteger.ZERO;
            this.outflow = BigInteger.ZERO;
       }
       public void set(BigInteger inflow, BigInteger outflow) {
            this.inflow = inflow;
            this.outflow = outflow;
       }
       @override
        public void write(DataOutput out) throws IOException {
            out.writeUTF(inflow.toString());
            out.writeUTF(outflow.toString());
       }
       @override
       public void readFields(DataInput in) throws IOException {
            inflow = new BigInteger(in.readUTF());
            outflow = new BigInteger(in.readUTF());
       }
```

以下是 map 函数的主要功能语句:

```
String userIdField = fields[0];
BigInteger directPurchaseAmt = new BigInteger(fields[5]);
BigInteger totalRedeemAmt = new BigInteger(fields[8]);

userId.set(userIdField);
if (directPurchaseAmt.compareTo(BigInteger.ZERO) > 0 ||
totalRedeemAmt.compareTo(BigInteger.ZERO) > 0) {
   context.write(userId, one);
} else {
   context.write(userId, new LongWritable(0)); // Count as active day even if
amounts are zero
}
```

注意:实验开始前要对 user_balance_table.csv 中的第一行删去,第一行并不是需要统计的内容。

1.2、Reducer的设计思路

Reducer 包含有 reduce 函数和 cleanup 函数。

1. reduce **函数**就是实现对于同一个key的 Iterable<LongWritable> values 中的每一个元素按照 userID 作为键,对于活跃天数进行求和操作。最后把统计完成的键值对,存入 Map<Long, List<Text>> activeDaysMap = new TreeMap<>(Comparator.reverseOrder()),这个 activeDaysMap 变量存入的元素是一个键值对为(**活跃天数,userID列表**),可以实现按照 key 即**活跃天数**进行**倒序排列**,以待 cleanup 函数实现对输出格式的处理。 以下是 reduce 函数的主要功能语句:

```
private LongWritable result = new LongWritable();
private Map<Long, List<Text>> activeDaysMap = new TreeMap<>
(Comparator.reverseOrder());

@override
protected void reduce(Text key, Iterable<LongWritable> values, Context
context) throws IOException, InterruptedException {
    long activeDays = 0;
    for (LongWritable val : values) {
        activeDays += val.get();
    }
    result.set(activeDays);

activeDaysMap.computeIfAbsent(activeDays, k -> new ArrayList<>
()).add(new Text(key));
}
```

2. cleanup 函数就是实现对输出结果的格式控制。对于 reduce 函数中实现的键为活跃天数,值为 userID列表,这已经按照活跃天数完成了倒序排序了,所以只需要把键值对的userID列表展开依 次输出即可。

以下是 cleanup 函数的主要功能语句:

```
for (Map.Entry<Long, List<Text>>> entry : activeDaysMap.entrySet()) {
   for (Text userId : entry.getValue()) {
      context.write(userId, new LongWritable(entry.getKey()));
   }
}
```

1.3、项目运行的配置设计

- 此次项目主要使用 Maven 进行项目管理,通过编辑 pom.xml 文件对该项目进行配置。 pom.xml 文件的配置信息包含有该项目需要哪些库文件需要下载,该项目的项目文件有哪些。
- 依次使用 mvn clean install 进行配置,同时还可以使用 mvn compile 对 .class 文件进行生成, mvn package 实现对项目文件的 .class 文件打包成 jar 文件。
- 将 user_balance_table.csv 上传至**HDFS**的 / input 文件夹里面,最后运行该项目的 jar 文件,运行命令为:

```
./hadoop jar /home/njucs/shiyan2_3/target/shiyan2_3-1.0-SNAPSHOT.jar
ActiveDaysCount /input /output_3
```

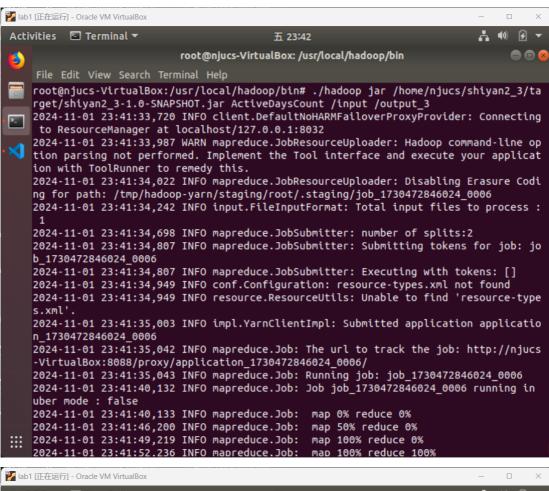
注意要把导出来的 part-r-00000解锁,以实现普通用户可以打开,命令如下:

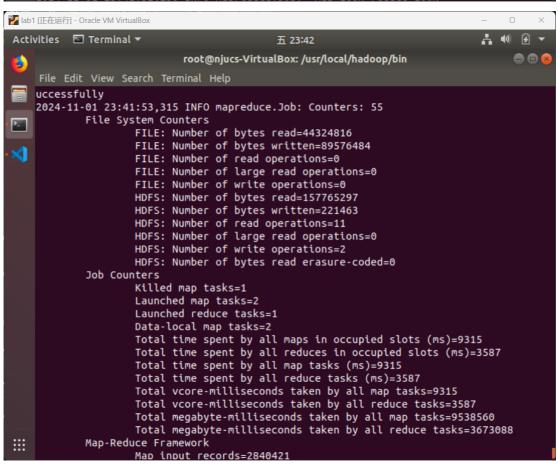
```
sudo chown $USER part-r-00000
```

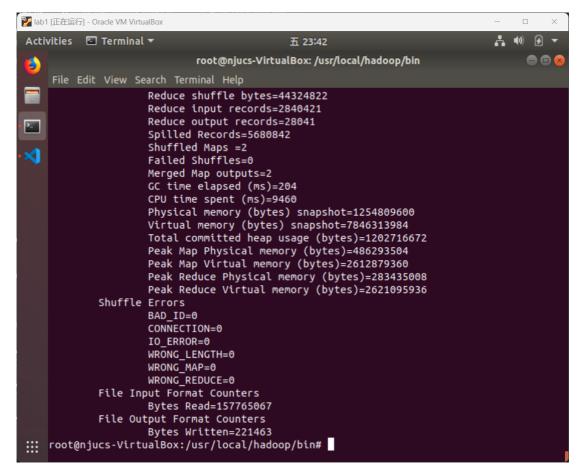
2、程序运行结果

以下即为 ActiveDaysCount.java 程序执行的任务三(根据 user_balance_table.csv 表中的数据,统计每个用户的活跃天数,并按照活跃天数降序排列。输出格式为" < 用户 ID> TAB < 活跃天数 >")的运行结果:

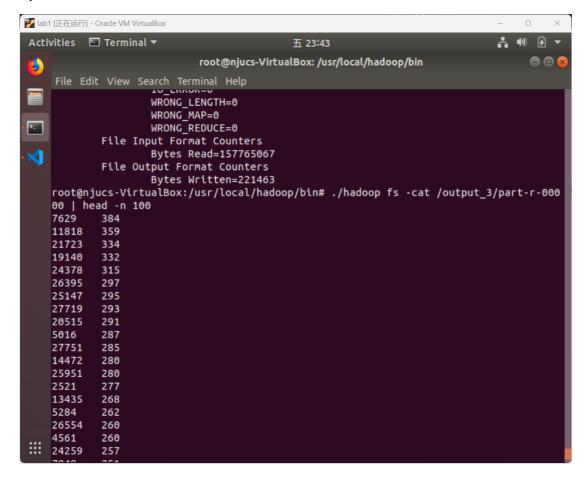
• 程序运行结果图:







• part-r-00000输出结果图:



3、WEB页面截图

因为我的代码一开始写的有bug,所有修改了4次,也就运行了5次,第5次程序运行结果符合预期,任务三完成。

